

EDGE IA

Table des matières

I. Introduction	3
II. Comprendre l'Edge IA	5
1. IA Cloud vs IA Edge	5
2. Appareils Edge : du capteur au smartphone.....	6
3. Adapter l'IA à des ressources limitées	6
4. Exemples pratiques d'Edge IA	6
III. Les avantages de l'Edge AI	9
1. Latence réduite	9
2. Bande passante optimale	10
3. Sécurité des données et confidentialité.....	11
4. Fiabilité et autonomie des systèmes.....	11
5. Efficacité énergétique et coût.....	12
IV. État de l'art de l'Edge AI.....	13
1. Progrès récents dans le matériel (hardware).....	13
a) Les avancées récentes dans le matériel dédié à l'Edge AI : Une révolution silencieuse	13
b) NVIDIA Jetson : La référence pour l'Edge AI	13
c) Qualcomm Snapdragon AI : L'IA au bout des doigts	14
d) D'autres acteurs à suivre	14
2. Algorithmes d'IA optimisés pour l'Edge	15
a) Pruning	15
b) Quantification	16
c) Distillation des connaissances.....	16
3. Rôle de la 5G dans le développement de l'Edge AI	18
d) Pourquoi la 5G est un catalyseur pour l'Edge AI ?	18
e) Comment la 5G améliore les performances de l'Edge AI ?	19
4. Logiciels et Framework dédiés à l'Edge AI	20
a) TensorFlow Lite : Légèreté et simplicité pour l'Edge.....	20

b) PyTorch Mobile : La puissance de PyTorch, adaptée à l'Edge	21
c) Autres frameworks à connaître.....	22
V. Les divers défis de l'Edge AI	23
1. Les défis matériels	23
a) Puissance de calcul réduite	23
b) Contraintes énergétiques	24
c) Capacités de stockage limitées	24
d) Résistance aux environnements hostiles	24
2. Défis éthiques et juridiques	24
a) Confidentialité et sécurité des données	24
b) Conformité réglementaire.....	24
c) Biais et équité.....	25
d) Impact sociétal	25
VI. Solutions aux défis de l'Edge AI	25
1. Développement de processeurs spécialisés pour l'Edge AI	25
2. Compression et optimisation des modèles IA	26
a) Quantification	26
b) Prunage (Pruning)	26
c) Distillation de connaissances	27
3. Intégration de systèmes hybrides (Edge-Cloud).....	28
4. Mise en place de normes et protocoles de sécurité avancés.....	29
5. Conformité proactive avec les réglementations	29
6. Développement d'algorithmes anti-biais.....	30
7. Sensibilisation et éducation des développeurs	31
VII. Perspectives et opportunités d'avenir	31
1. Améliorations attendues dans les puces et algorithmes	31
2. Nouvelles applications potentielles.....	31
3. Effets de la réglementation sur le développement de l'Edge AI.....	32
4. Collaboration entre le cloud et l'Edge AI	32
VIII. Études de cas	33
1. Exemple de mise en œuvre réussie dans l'industrie automobile	33

2.	Cas d'une ville intelligente utilisant l'Edge AI	33
3.	Utilisation de l'Edge AI dans le secteur de la santé	33
IX.	Cas pratique	34
1.	Base de données	34
2.	Technologies adaptées.....	35
3.	Modèles et évaluation	36
4.	Environnement de développement	37
5.	Interface utilisateur	37
X.	Recommandations pour l'implémentation de l'Edge AI.....	38
1.	Stratégies pour intégrer l'Edge AI dans les entreprises	38
2.	Pratiques exemplaires pour la sécurité et la maintenance	39
3.	Approches pour réduire la consommation d'énergie.....	39
4.	Collaboration avec les fournisseurs de technologies	40
XI.	Conclusion	40
XII.	Bibliographie et Annexes.....	41

I. Introduction

Dans le monde de l'informatique, l'intelligence artificielle est devenue un sujet d'actualité depuis ces quatre dernières années. Notamment avec l'arrivée de l'IA générative, le sujet est présent partout : dans les entreprises, dans la recherche, dans les médias, et même dans la politique. Les pionniers de l'intelligence artificielle nous promettent un quotidien amélioré, des tâches fastidieuses automatisées en quelques clics, une analyse d'énormes quantités de données sans souci, mais aussi une aide aux utilisateurs pour prendre des décisions éclairées. Nous l'associons souvent à une série d'algorithmes très complexes, hébergés dans de puissants serveurs dans le cloud et capables de traiter à distance toutes nos requêtes. Pourtant, une approche différente est apparue ces dernières années, nommée « intelligence artificielle en périphérie » ou plus communément appelée « Edge IA ».

Le but de cette nouvelle technologie est de rapprocher l'IA des appareils et des utilisateurs. Au lieu d'envoyer toutes les données dans le cloud, l'IA est directement intégrée dans de petits appareils tels que des capteurs, des caméras, des smartphones, des montres connectées, des voitures, des drones, etc. Cela permet aux appareils situés en périphérie du réseau de devenir intelligents. Ces derniers analysent les données localement sans dépendre d'un serveur

distant. Cette innovation est particulièrement intéressante dans des contextes où la connexion Internet n'est pas toujours disponible, où la latence doit être réduite au minimum, ou encore lorsqu'on veut protéger la vie privée de l'utilisateur en traitant localement certaines informations sensibles.

Alors, pourquoi s'intéresser à ce sujet maintenant ? Il y a plusieurs raisons. D'abord, on assiste à une explosion du nombre d'objets connectés. Les objets du quotidien deviennent intelligents et sont de plus en plus nombreux : capteurs dans l'industrie, appareils de domotique, drones, véhicules autonomes, dispositifs médicaux portables, etc. Ces objets nécessitent un financement coûteux si l'on décide de transférer toutes leurs données dans le cloud, de plus, le traitement peut être très lent et peu pratique. Le progrès matériel a rendu possible l'intégration de puces IA et de processeurs très efficaces même dans de petits appareils. Il y a quelques années, imaginer avoir des ressources suffisantes pour effectuer des calculs puissants, tels que faire tourner des modèles de reconnaissance d'images sur des smartphones, était impensable, contrairement à aujourd'hui. Aussi, la sécurité des données personnelles est un sujet pris très au sérieux à notre époque : traiter ces informations localement sans les envoyer à un serveur distant, c'est s'assurer un plus grand contrôle sur ses données.

Le but de ce rapport est d'offrir une vision d'ensemble de ce qu'est l'Edge IA, de ses avantages, de ses limites et de ses applications concrètes. L'idée est d'expliquer le concept, de montrer les domaines où cela s'applique, et de comprendre les défis qui restent à relever.

Dans ce rapport, on présentera ce qu'est l'IA en périphérie, en la comparant à l'IA classique dans le cloud. On abordera ensuite ses avantages, comme le fait d'améliorer la rapidité ou de fonctionner hors ligne. Mais aussi les défis, notamment techniques, financiers et éthiques. On parlera de la technologie disponible en ce moment pour intégrer de l'IA au niveau des appareils, ainsi que des différentes méthodes pour optimiser les modèles afin qu'ils soient moins gourmands en ressources. On analysera les secteurs où l'Edge IA est déjà présente : l'industrie, les villes intelligentes, la santé, l'automobile, l'agriculture connectée, et bien d'autres. On abordera également les questions de sécurité et de confidentialité, qui sont très importantes dans ce domaine. Enfin, on parlera de l'avenir et des technologies qui pourraient révolutionner votre monde dans quelques années.

En bref, l'Edge IA représente le progrès auquel l'intelligence artificielle et l'internet des objets sont confrontés : au lieu d'avoir un modèle centralisé où tout passe par des serveurs distants, nous développons un modèle local, plus proche de l'appareil. Cela s'accompagne de nombreux avantages, mais aussi de nouveaux problèmes à résoudre. Ce mémoire tente d'explorer ce sujet de manière claire et abordable, afin de mieux comprendre cet univers passionnant.

II. Comprendre l'Edge IA

1. IA Cloud vs IA Edge

Pour bien comprendre ce qu'est l'Edge IA, il est d'abord nécessaire de rappeler un concept que l'on connaît déjà : l'intelligence artificielle dans le cloud. Pendant longtemps, lorsqu'on parlait d'IA, on imaginait de gigantesques serveurs s'étendant à perte de vue, situés quelque part dans le monde, capables d'analyser d'énormes quantités de données. Lorsqu'un utilisateur prend une photo, par exemple, il envoie cette donnée vers le cloud, l'IA effectue alors un travail de détection, de classification ou de prévision, puis renvoie un résultat. Ce concept présente des avantages tels qu'une puissance de calcul illimitée, une mise à jour facile des modèles et une grande flexibilité, etc. Néanmoins, on observe aussi certains inconvénients : le besoin constant d'une connexion Internet, une vitesse de calcul parfois insuffisante, une sécurité qui peut laisser à désirer et un coût important en bande passante.

L'Edge IA propose une solution plus adaptée à ces besoins : au lieu d'envoyer ces données vers le cloud, on intègre l'IA directement dans l'appareil, de façon locale, ce que l'on appelle un « device edge ». Ces « devices edge » peuvent être des caméras intelligentes capables de reconnaître des visages, des capteurs industriels détectant des anomalies, des compteurs d'énergie connectés, ou encore des smartphones comprenant les commandes vocales sans passer par un serveur distant. Le traitement se fait localement, sans avoir recours à une connexion Internet. Le device edge comprend un processeur, de la mémoire et éventuellement des accélérateurs matériels spécialisés (comme des TPU) qui rendent possible l'exécution de modèles d'IA.

Ceux qui pensent que l'Edge IA consiste uniquement à effectuer des calculs localement n'ont pas pleinement saisi le concept. Cela implique aussi des ressources matérielles plus limitées : moins de puissance, moins de mémoire, moins d'énergie disponible. Les modèles utilisés sont

souvent plus simples et plus légers. L'idée est de conserver une qualité de prédiction correcte tout en tenant compte des contraintes de l'appareil.

2. Appareils Edge : du capteur au smartphone

Les types d'appareils edge sont très variés. On peut penser aux objets de l'Internet des objets (IoT), comme des capteurs dans une usine : ces capteurs mesurent en continu la température, la pression, les vibrations, etc. Le but est de détecter automatiquement une anomalie (par exemple, une vibration anormale qui pourrait indiquer une machine défaillante) et d'envoyer une alerte instantanément. Auparavant, il aurait fallu transférer toutes ces données vers le cloud et attendre le traitement par le modèle. Aujourd'hui, on peut utiliser un drone équipé d'une caméra, ce dernier étant capable de reconnaître des obstacles ou d'analyser un champ pour détecter des zones mal desservies, le tout sans devoir utiliser la 4G ou toute autre connexion Internet. Un autre exemple : un smartphone qui comprend les commandes vocales hors ligne, pratique lorsqu'on se trouve en montagne ou dans une zone à faible connectivité.

3. Adapter l'IA à des ressources limitées

L'Edge IA requiert un développement différent de ses modèles. Lorsqu'on utilise le cloud, on a tendance à employer des GPU et des TPU très puissants pour l'entraînement. En edge, on doit entraîner ces modèles dans le cloud puis les déployer une version simplifiée, ou bien concevoir dès le départ des modèles adaptés aux appareils peu puissants. L'entraînement peut également être distribué via des techniques comme l'apprentissage fédéré, où différents appareils participent à l'entraînement d'un modèle global sans que leurs données ne quittent jamais leur appareil.

4. Exemples pratiques d'Edge IA

Enfin, il faut comprendre que l'Edge IA et l'IA dans le cloud ne sont pas forcément opposées ou exclusives. Au contraire, de nombreuses applications pratiques utilisent un mélange des deux. Par exemple, un smartphone pourrait effectuer une première analyse basique en local, puis envoyer un résumé des résultats au cloud pour une analyse plus approfondie. Un véhicule autonome pourrait détecter les obstacles en local, mais envoyer certaines données vers le

cloud pour améliorer son modèle ou pour un diagnostic à plus long terme. L'Edge IA vient donc compléter les approches cloud, offrant ainsi davantage de flexibilité et de robustesse.




Figure 1 : Comparaison entre IA dans le Cloud et Edge IA [1]

Comparaison entre l'Edge AI et le Cloud AI

Ceux sont deux paradigmes complémentaires de l'intelligence artificielle. Le Cloud IA centralise le traitement des données pour une analyse approfondie, tandis que l'Edge IA effectue le traitement localement pour répondre aux besoins immédiats.

Un tableau comparatif pour avoir un résumé clair et afin d'étudier la différence sur les éléments principaux

Élément	Edge IA	Cloud IA
Lieu de traitement	Traitement sur l'appareil ou presque.	Centralisé sur des serveurs distants.

Latence	Très faible, adapté aux applications en temps réel.	Plus élevé en raison des besoins de transfert de données supplémentaires.
Confidentialité	Les données sont stockées sur l'appareil, ce qui améliore la sécurité.	Plus de vulnérabilité aux fuites de données pendant le transfert de données.
Dépendance à la bande passante	Faible.	Fortement dépendant de la connectivité réseau.
Puissance de calcul	Limitée aux ressources de l'appareil.	Élevée, grâce à une puissance de serveur massive.
Coût	Coûts de transfert de données inférieurs.	Coûts de stockage et de calcul plus élevés

L'IA Edge est adapté dans des situations nécessitant des réponses rapides et indépendantes telles que les voitures autonomes, les appareils médicaux et les smart cities.

Le Cloud IA est opté dans des situation avec des grandes quantités de calculs et où la collaboration est à l'échelle mondiale, comme exemple l'analyse de Big Data, la création de modèles d'intelligence artificielle complexes ainsi que les applications qui requièrent une coordination interrégionale.

Il est évident que Edge AI et Cloud AI sont liés, et dans de nombreux cas, les deux méthodes fonctionnent harmonieusement ensemble. Deux cas concrets peuvent être observés qui mettent en évidence cette dépendance. Dans un premier exemple, une caméra intelligente a la capacité d'analyser des images en utilisant Edge IA en local et de repérer les anomalies afin de mener une enquête plus approfondie. Dans un autre domaine, les informations médicales d'un patient sont examinées localement afin de fournir des alertes précoces, mais également regroupées dans le cloud pour des études à long terme.




Figure 2 : Exemple d'application de caméra avec Edge IA [10]

L'Edge AI est l'évolution naturelle de l'Edge Computing, rendue possible grâce aux progrès technologiques récentes et la demande croissante de traitement local des données. Alors que l'IA cloud reste au cœur du calcul centralisé du big data, l'Edge AI offre une application améliorée c'est à dire plus réactive, plus sécurisée et plus autonome. Cela n'empêche que ces deux approches restent dans des cas dépendants, fonctionnant souvent ensemble pour répondre aux exigences modernes en matière de traitement des données.

III. Les avantages de l'Edge AI

L'IA Edge offre des avantages considérables par rapport au cloud Computing conventionnel, en particulier dans les scénarios qui exigent des temps de réponse rapides, une confidentialité améliorée et des dépenses réduites. Cette section examine ses principaux avantages.

1. Latence réduite

La latence correspond au temps écoulé entre la collecte des données et leur traitement ultérieur et joue un rôle important dans de nombreuses applications qui s'exécutent en temps réel.

On peut constater l'importance de la faible latence dans les applications de secteurs critiques telles que les voitures autonomes et les dispositifs médicaux.

Par exemple une longue période de retard de traitement des données venant des capteurs comme caméras, radars et LIDAR pour les voitures autonomes peut conduire à des prises de décision tardives qui pourraient mener à une situation dangereuse ou même être une cause pour des catastrophes. Comme pour le freinage d'urgence, il requiert une réponse presque immédiate.

Dans le cas où on est obligé d'envoyer des données au cloud pour le traitement, il est possible que le temps de réponse soit lent, ce qui pourrait entraîner des accidents.




Figure 3 : a) Exemple d'une solution Edge IA pour véhicule autonome ; b) Analyse des différences entre le pipeline logiciel traditionnel de conduite autonome et les pipelines logiciels complets et partiels. [14]

Dans un autre domaine où le temps est un élément très important qui est le secteur médical, lorsque des anomalies sont détectées, les stimulateurs cardiaques et les capteurs de surveillance cardiaque, par exemple, doivent émettre des alertes immédiates. L'intervention rapide est possible grâce au traitement local. Grâce à l'IA Edge, les montres intelligentes sont capables de repérer des anomalies cardiaques et de prévenir un porteur en quelques secondes.

En Comparaison avec l'IA dans le cloud, le cloud Computing nécessite l'envoi de données vers des serveurs distants tel que le cloud afin de les traiter, ce qui entraîne une augmentation des délais de traitement. Grâce à l'Edge, les informations sont traitées dans les appareils en local, ce qui diminue la latence à quelques millisecondes.

2. Bande passante optimale

La croissance exponentielle des données générées par les appareils connectés nécessite de réduire la quantité de données envoyées au cloud. Les bénéfices de la réduction de la transmission des informations sont nombreux et sont illustrés par plusieurs exemples concrets. En premier lieu, les conditions de connectivité limitées représentent un défi important dans les régions éloignées telles que les campagnes ou les zones industrielles, où il n'est pas toujours possible d'avoir une connectivité stable et un débit élevé. Dans ces contextes, l'intelligence artificielle Edge permet de traiter les données en local, ce qui empêche les surcharges du réseau et assure un fonctionnement autonome. Par exemple, dans le secteur agricole intelligent analyser en temps réel les données provenant de capteurs à proximité afin d'ajuster les systèmes d'irrigation sans avoir besoin d'une connexion continue à un serveur lointain. En outre, le Cloud Computing aide à minimiser les dépenses liées à la transmission

des données, en réduisant la consommation de bande passante. Ce bénéfice est d'une importance particulière dans les cas où la connectivité est coûteuse ou restreinte, ce qui est le cas dans les zones mal couvertes par les infrastructures numériques, ce qui permet d'optimiser l'utilisation des ressources sans négliger un traitement efficace des données.

3. Sécurité des données et confidentialité

La gestion des données sur des dispositifs Edge permet de diminuer les dangers associés à la transmission des informations et renforce la sécurité des données confidentielles. En gérant les données localement, il restreint les attaques cybernétiques, car les informations ne sont pas transmises sur le réseau, ce qui diminue les risques de violation. À titre d'exemple, des dispositifs médicaux tels que les glucomètres intelligents conservent directement les informations des patients, assurant ainsi leur confidentialité. En outre, cette méthode rend plus facile le respect des réglementations comme le RGPD en Europe, en évitant le transfert de données vers des serveurs externes. L'utilisation de l'IA Edge permet à une application bancaire d'analyser les transactions localement afin de repérer les fraudes sans divulguer les informations confidentielles des clients. De la même manière, les caméras de surveillance intelligentes ont la capacité de traiter les flux vidéo en temps réel afin de repérer des incidents sans transmettre de données au cloud, garantissant ainsi une confidentialité accrue des images capturées.

4. Fiabilité et autonomie des systèmes

La capacité de l'Edge IA à fonctionner de manière autonome, même sans connexion réseau, en fait un avantage important pour de nombreux domaines. Cette autonomie garantit une continuité opérationnelle pour les systèmes Edge, même dans des environnements instables ou dépourvus de connectivité. Par exemple, en campagne, des drones agricoles équipés d'Edge IA peuvent étudier les cultures sans avoir besoin d'être constamment connectés à Internet. Cette autonomie contribue également à diminuer les interruptions : en cas de dysfonctionnement du réseau, un système utilisant Edge IA peut poursuivre l'exécution de tâches essentielles, à la différence des solutions qui sont dépendantes du cloud. De cette manière, une usine dotée de capteurs intelligents a la possibilité de surveiller en temps réel l'état de ses machines afin de prévenir d'éventuelles pannes sans nécessiter d'intervention extérieure.

Le secteur médical et l'industrie sont parmi les secteurs les plus critiques. Un dispositif de surveillance médicale peut maintenir l'enregistrement des signes vitaux d'un patient tels que le rythme cardiaque

ou bien la tension artérielle et émettre des alertes locales si besoin pour prévenir les patients au cas d'une mesure anormale.

Dans l'industrie, afin de garantir un bon fonctionnement et une efficacité sure, les capteurs de maintenance prédictive fonctionnent de manière autonome.

5. Efficacité énergétique et coût

L'Edge AI a joué un rôle important dans la diminution des couts opérationnelles et de la consommation d'énergie, surtout dans un contexte où les données produites par les appareils connectés augmentent de manière exponentielle. En restreignant le flux de données superflues, l'Edge AI a amélioré l'efficacité des ressources réseau et diminue les coûts associés à la bande passante et à l'infrastructure réseau. Par exemple, dans les villes intelligentes, des appareils comme les capteurs de pollution effectuent une analyse locale des données et ne transmettent que les informations pertinentes au cloud, ce qui permet d'économiser des ressources considérables. Grâce à cette méthode, les entreprises peuvent également réduire leurs dépenses liées à l'achat de serveurs cloud coûteux en transférant une partie du traitement directement sur les terminaux locaux. L'effet sur la consommation d'énergie est aussi spectaculaire. Les caméras de surveillance intelligentes peuvent être programmées avec une logique qui permet de transmettre uniquement des événements critiques, tels que les activités suspectes ou bien lors de la présence des événements anormaux et inhabituels, plutôt que de diffuser en continu des flux vidéo. Le but c'est de diminuer le volume de la transmission pour des activités normales qui ne dérange pas l'activité des appareils connectés, de ce fait la réduction des coûts.

La solution d'Edge a été développés pour être économiques en énergie, ce qui est important pour les appareils alimentés par batterie, tels que les capteurs IoT utilisés dans les secteurs industriels, qui peuvent durer des mois sans avoir besoin de recharge. De plus, l'Edge AI diminué le volume de données transférées vers le cloud, un processus qui est connu pour être très énergivore. Ce qui permet aux entreprises de réduire leur empreinte carbone avec une performance non dégradable.

En comparaison avec les systèmes qui consomment du cloud, qui nécessitaient de grandes fermes de serveurs pour le stockage et le traitement, l'Edge AI se démarque comme une solution plus respectueuse de l'environnement et économique qui respecte les normes de l'environnement, capable de satisfaire les besoins croissants en matière de traitement de données tout en précisant les conséquences sur l'environnement.

IV. État de l'art de l'Edge AI

1. Progrès récents dans le matériel (hardware)

a) Les avancées récentes dans le matériel dédié à l'Edge AI : Une révolution silencieuse

Les progrès de l'Edge AI ne se limitent pas aux logiciels ou aux algorithmes : le matériel (ou hardware) joue un rôle clé dans cette transformation. Grâce aux nouvelles puces spécialement conçues pour l'intelligence artificielle en périphérie, on peut désormais exécuter des modèles d'IA directement sur des appareils locaux, sans dépendre du cloud. Cela change la donne dans des domaines comme la robotique, les smartphones ou encore les systèmes embarqués. Deux acteurs majeurs, NVIDIA et Qualcomm, se démarquent particulièrement avec leurs innovations.

b) NVIDIA Jetson : La référence pour l'Edge AI

NVIDIA, connue pour ses GPU performants, a mis au point la gamme **Jetson**, des modules conçus pour les applications d'IA en périphérie. Ils sont très prisés dans des secteurs comme la robotique, les drones, ou encore les véhicules autonomes.

- **Jetson AGX Orin**, par exemple, est un véritable concentré de puissance. Avec une capacité impressionnante de calcul (jusqu'à 275 TOPS, soit 275 trillions d'opérations par seconde), il permet de faire tourner des modèles d'IA complexes comme ceux utilisés pour la reconnaissance d'images 3D ou la fusion de données provenant de plusieurs capteurs. Ce qui est bluffant, c'est qu'il parvient à offrir ces performances tout en restant très économe en énergie.

Pour des besoins plus modestes, **Jetson Orin Nano** est une option plus abordable, idéale pour des applications simples mais toujours exigeantes en matière d'IA. Malgré sa taille compacte, il surpasse de loin ses prédécesseurs avec une puissance jusqu'à 80 fois supérieure !

Ces modules sont accompagnés d'un écosystème logiciel complet, ce qui simplifie grandement leur adoption. En clair, les développeurs disposent de tous les outils nécessaires pour concevoir et déployer des solutions directement en périphérie.



Figure 4 : Logo de NVIDIA, entreprise développant la gamme Jetson pour l'Edge AI

c) Qualcomm Snapdragon AI : L'IA au bout des doigts

Qualcomm, de son côté, révolutionne les appareils mobiles grâce à sa gamme **Snapdragon**, qui intègre des capacités avancées d'intelligence artificielle. Si vous utilisez un smartphone performant, il y a de grandes chances qu'il fonctionne avec une puce Snapdragon.

- La dernière innovation, le **Snapdragon 8 Elite**, est un bijou technologique. En plus de son rôle classique dans les smartphones, cette puce permet désormais de réaliser des tâches avancées comme la génération d'images ou de textes, directement sur l'appareil. Imaginez : pas besoin de se connecter au cloud, tout se fait en local, ce qui améliore à la fois la rapidité et la confidentialité.
- Un autre atout de Qualcomm, c'est son processeur spécialisé, le **Hexagon DSP**, conçu pour traiter des tâches d'IA avec une efficacité énergétique exceptionnelle. Cela signifie que vous pouvez utiliser des fonctionnalités comme la reconnaissance vocale ou la traduction instantanée sans vider la batterie de votre téléphone.



Figure 5 : Logo de Snapdragon, une référence dans les processeurs pour l'Edge AI

d) D'autres acteurs à suivre

Au-delà de NVIDIA et Qualcomm, d'autres entreprises poussent les limites du matériel Edge AI. Par exemple :

- **NVDLA (NVIDIA Deep Learning Accelerator)** est une architecture matérielle open-source. Son objectif est de faciliter l'intégration de l'intelligence artificielle dans une large gamme de dispositifs, des caméras de sécurité aux équipements médicaux.
- **Tegra Orin**, également développé par NVIDIA, combine des cœurs de processeurs avancés avec une puissance graphique impressionnante, le tout dans une seule puce. Elle est particulièrement adaptée aux applications exigeantes comme les voitures autonomes.

2. Algorithmes d'IA optimisés pour l'Edge

Quand on parle d'intelligence artificielle, on pense souvent à de gros modèles gourmands en ressources, sur des serveurs puissants dans des centres de données. Mais l'Edge AI exige autre chose : des modèles plus légers, rapides et capables de fonctionner sur des appareils aux ressources limitées, comme un smartphone ou une caméra connectée. Pour relever ce défi, plusieurs techniques d'optimisation sont émergées. Trois des plus importantes sont le **Pruning**, la **Quantification**, et la **Distillation des connaissances**.

a) Pruning

Le Pruning consiste à supprimer les parties du modèle qui ne sont pas essentielles pour ses performances. Imaginez un grand arbre avec des branches inutiles : en les retirant, l'arbre reste fonctionnel tout en étant plus léger.

- **Extrait de code**

```
import tensorflow as tf
from tensorflow_model_optimization.sparsity.keras import prune_low_magnitude

# Charger un modèle pré-entraîné
model = tf.keras.applications.MobileNetV2(weights='imagenet')

# Appliquer le pruning
pruning_params = {
    'pruning_schedule': tf.keras.optimizers.schedules.PolynomialDecay(
        initial_sparsity=0.0, final_sparsity=0.5, decay_steps=1000)
}

pruned_model = prune_low_magnitude(model, **pruning_params)
```

- **Explication**

L'idée ici est simple : on identifie les connexions dans le réseau neuronal (les "poids") qui ont très peu d'impact sur les prédictions du modèle. Ensuite, on les supprime. Par exemple, si un poids a une valeur proche de zéro, il contribue très peu au résultat final. En les enlevant, le modèle devient plus rapide et consomme moins de mémoire, sans perdre en précision – du moins, si c'est bien fait.

b) Quantification

La quantification vise à réduire la taille des nombres utilisés pour représenter les poids et les activations d'un modèle. Par défaut, ces valeurs sont souvent stockées en **float32** (des nombres à virgule flottante codés sur 32 bits). La quantification peut les ramener à **int8** (entiers codés sur 8 bits), ce qui réduit drastiquement la mémoire utilisée.

- **Extrait de code**

```
import tensorflow as tf

# Charger un modèle et le convertir en format TFLite
converter = tf.lite.TFLiteConverter.from_keras_model(model)
converter.optimizations = [tf.lite.Optimize.DEFAULT]
quantized_model = converter.convert()

# Sauvegarder le modèle quantifié
with open('quantized_model.tflite', 'wb') as f:
    f.write(quantized_model)
|
```

- **Explication**

Pour résumer on sacrifie un peu de précision dans les calculs pour obtenir un modèle beaucoup plus léger et rapide. Imaginez que vous utilisiez des décimales très précises pour mesurer une distance en kilomètres, alors qu'une précision au mètre suffit largement pour votre application. C'est la même logique ici : on simplifie les calculs en acceptant une très légère perte de précision et le tour est joué.

c) Distillation des connaissances

La distillation des connaissances (ou knowledge distillation) est une méthode ingénieuse. Elle consiste à entraîner un petit modèle (appelé "étudiant") en le faisant apprendre non pas directement à partir des données brutes, mais à partir des prédictions d'un grand modèle (appelé "enseignant").

- **Extrait de code**

```
import tensorflow as tf

# Charger un modèle et le convertir en format TFLite
converter = tf.lite.TFLiteConverter.from_keras_model(model)
converter.optimizations = [tf.lite.Optimize.DEFAULT]
quantized_model = converter.convert()

# Sauvegarder le modèle quantifié
with open('quantized_model.tflite', 'wb') as f:
    f.write(quantized_model)

import tensorflow as tf

teacher_model = tf.keras.applications.MobileNetV2(weights='imagenet')

student_model = tf.keras.Sequential([
    tf.keras.layers.Input(shape=(224, 224, 3)),
    tf.keras.layers.Conv2D(32, 3, activation='relu'),
    tf.keras.layers.Flatten(),
    tf.keras.layers.Dense(1000, activation='softmax')
])

# Entraîner l'étudiant avec les prédictions de l'enseignant
for x, y in dataset:
    teacher_preds = teacher_model(x)
    student_model.train_on_batch(x, teacher_preds)
```

- **Explication**

L'idée est de simplifier. Le grand modèle (enseignant) connaît bien les données et peut transmettre des "indices" précieux sur ce qui est important. Cela permet au petit modèle (étudiant) de se concentrer sur l'essentiel, tout en étant beaucoup moins gourmand en ressources.

Pourquoi ces techniques sont cruciales pour l'Edge AI ?

Ces techniques permettent de faire tourner des modèles puissants directement sur des appareils locaux, sans dépendre du cloud. Cela signifie :

- **Plus de rapidité** : Les données n'ont pas besoin de voyager jusqu'à un serveur. Tout est traité sur place.
- **Moins de consommation énergétique** : Idéal pour des appareils avec des batteries, comme les drones ou les montres connectées.
- **Meilleure confidentialité** : Les données restent sur l'appareil, ce qui réduit les risques de fuite ou de piratage.

3. Rôle de la 5G dans le développement de l'Edge AI

Comment la 5G facilite le déploiement de l'Edge AI avec une latence réduite ?

L'Edge AI et la 5G sont deux technologies qui se complètent parfaitement. Alors que l'Edge AI se concentre sur le traitement des données en périphérie (directement sur les appareils), la 5G offre une infrastructure réseau rapide, fiable et à faible latence. Ensemble, elles ouvrent de nouvelles possibilités pour des applications en temps réel qui étaient auparavant inaccessibles.

a) Pourquoi la 5G est un catalyseur pour l'Edge AI ?

La 5G n'est pas seulement une version améliorée de la 4G : elle apporte des caractéristiques clés qui en font un allié idéal pour l'Edge AI.

Faible latence : Alors que la 4G a une latence typique d'environ 50 millisecondes, la 5G peut réduire ce délai à moins de 1 milliseconde. Cela signifie que les appareils peuvent communiquer presque instantanément, ce qui est crucial pour des applications comme les véhicules autonomes ou la réalité augmentée.

Haute bande passante : Avec des débits de plusieurs gigabits par seconde, la 5G peut gérer des flux massifs de données, comme ceux générés par des caméras HD ou des capteurs IoT (Internet of Things), sans ralentissement.

Connectivité massive : La 5G permet de connecter des millions de dispositifs dans une petite zone géographique, une condition essentielle pour des environnements comme les usines intelligentes ou les villes connectées.

Des applications concrètes rendues possibles par la 5G et l'Edge AI

- **Véhicules autonomes**

Les voitures autonomes doivent prendre des décisions en une fraction de seconde. Grâce à l'Edge AI, elles peuvent analyser des données provenant de leurs caméras et capteurs directement à bord. Cependant, certaines décisions critiques nécessitent des informations provenant d'autres véhicules ou d'une infrastructure connectée (comme des feux de signalisation intelligents). La 5G garantit que ces communications se fassent en temps réel, sans décalage.

- **Industrie 4.0**

Dans les usines intelligentes, les robots et les machines connectées doivent collaborer de manière fluide. L'Edge AI leur permet de traiter localement des données sur la production, tandis que la 5G assure une synchronisation parfaite entre tous les dispositifs, même dans des environnements à haute densité de connexions.

- **Santé connectée**

Imaginez une ambulance équipée de dispositifs d'Edge AI capable de surveiller en temps réel les signes vitaux d'un patient. Grâce à la 5G, ces données peuvent être partagées avec un hôpital avant même l'arrivée du véhicule, permettant au personnel médical de se préparer à l'avance.

b) Comment la 5G améliore les performances de l'Edge AI ?

- **Décentralisation intelligente**

La combinaison de la 5G et de l'Edge AI favorise une architecture décentralisée. Plutôt que de traiter toutes les données dans un cloud centralisé, les appareils peuvent s'appuyer sur des "mini-clouds" locaux situés à proximité (appelés MEC, ou Multi-access Edge Computing). Cela réduit le temps de réponse et diminue la dépendance à une connexion internet constante.

- **Réduction des besoins en matériel**

Avec la 5G, il devient possible d'exécuter certains calculs d'IA lourds dans des infrastructures proches (comme des antennes 5G équipées de serveurs), plutôt que directement sur l'appareil. Par exemple, un smartphone peut déléguer une partie des calculs d'IA à une station de base 5G, ce qui permet de prolonger sa batterie tout en bénéficiant de performances exceptionnelles.

- **Résilience et fiabilité**

La 5G introduit des mécanismes avancés de gestion des réseaux, comme le "network slicing", qui garantit une bande passante dédiée pour des applications critiques. Cela permet aux dispositifs d'Edge AI de continuer à fonctionner de manière fiable, même dans des environnements surchargés.

4. Logiciels et Framework dédiés à l'Edge AI

Présentation de logiciels et Framework populaires (TensorFlow Lite, PyTorch Mobile).

Afin de maximiser l'utilisation des capacités de l'Edge AI, il est nécessaire d'avoir des outils logiciels appropriés qui facilitent le développement, l'optimisation et le déploiement de modèles d'intelligence artificielle sur des appareils à ressources restreintes. Heureusement, de nombreux Framework tels que TensorFlow Lite et PyTorch Mobile ont été spécialement développés pour faire face à ce défi. Les développeurs peuvent utiliser des solutions flexibles et performantes pour concevoir des applications Edge AI sans avoir besoin d'être des spécialistes du matériel ou de l'optimisation des modèles.

a) TensorFlow Lite : Légèreté et simplicité pour l'Edge

TensorFlow Lite (TFLite) est une version allégée de TensorFlow, conçue pour exécuter des modèles d'apprentissage automatique sur des appareils comme les smartphones, les microcontrôleurs, ou même les puces spécialisées. Il se distingue par sa capacité à transformer des modèles volumineux en versions compactes tout en maintenant des performances élevées.

- **Fonctionnalités principales :**

Conversion et quantification : TensorFlow Lite permet de convertir des modèles TensorFlow classiques en formats optimisés pour l'Edge. Par exemple, un modèle en float32 peut être converti en int8 pour une exécution plus rapide et plus économe.

Interopérabilité avec le hardware : TFLite est compatible avec des accélérateurs matériels comme le TPU Edge de Google, garantissant des performances accrues.

Interface simple : Grâce à une API intuitive, il est facile de charger un modèle optimisé et de l'intégrer dans une application mobile.

- **Extrait de code :**

```
import tensorflow as tf

model = tf.keras.models.load_model('model.h5')

converter = tf.lite.TFLiteConverter.from_keras_model(model)
tflite_model = converter.convert()

with open('model.tflite', 'wb') as f:
    f.write(tflite_model)
```

- **Application concrète :**

TensorFlow Lite est principalement utilisé pour des tâches comme la reconnaissance d'images ou la détection d'objets directement sur des smartphones. Par exemple, les applications de vision par ordinateur peuvent détecter des objets en temps réel sans nécessiter de connexion à un cloud.

b) **PyTorch Mobile : La puissance de PyTorch, adaptée à l'Edge**

PyTorch Mobile est une extension de PyTorch, l'un des frameworks d'IA les plus populaires, qui permet d'exécuter des modèles directement sur des appareils mobiles et intégrés. Il est particulièrement apprécié pour sa flexibilité et ses capacités avancées de débogage.

- **Fonctionnalités principales :**

TorchScript : PyTorch Mobile utilise TorchScript pour convertir les modèles PyTorch en un format optimisé pour l'exécution sur des appareils aux ressources limitées. **Compatibilité multiplateforme :** Les modèles PyTorch Mobile peuvent fonctionner à la fois sur Android et iOS.

Support des optimisations matérielles : PyTorch Mobile peut tirer parti des accélérateurs matériels comme les GPU mobiles ou les processeurs ARM optimisés.

- **Extrait de code :**

```
import torch
import torchvision.models as models

model = models.resnet18(pretrained=True)

scripted_model = torch.jit.script(model)

scripted_model.save('model.pt')
```

- **Application concrète :**

PyTorch Mobile est souvent utilisé pour des applications comme le traitement du langage naturel (chatbots) ou la classification d'images sur des appareils mobiles. Par exemple, des assistants vocaux équipés de modèles optimisés avec PyTorch Mobile peuvent répondre aux requêtes en temps réel.

- c) Autres frameworks à connaître

- **Core ML (Apple)**

Apple a développé Core ML, une solution puissante et intuitive pour intégrer l'IA dans les appareils iOS. Il prend en charge des modèles optimisés pour fonctionner directement sur les puces des iPhones et iPads, notamment le Neural Engine intégré.

- **ONNX Runtime**

L'ONNX Runtime (Open Neural Network Exchange) permet d'exécuter des modèles provenant de différents frameworks comme TensorFlow et PyTorch sur des appareils Edge. Il est optimisé pour des accélérateurs matériels variés et offre une grande flexibilité.

- **MediaPipe**

Développé par Google, MediaPipe est une bibliothèque spécialisée pour les tâches multimédia, comme la reconnaissance de gestes, la détection faciale ou la segmentation d'images. Elle est souvent utilisée dans des applications de réalité augmentée.

V. Les divers défis de l'Edge AI

l'Edge AI – ou intelligence artificielle embarquée – c'est une avancée majeure dans le domaine de l'intelligence artificielle. Pourquoi ? Parce qu'elle permet d'amener les capacités d'analyse et de traitement directement sur les appareils en périphérie. Des appareils comme les capteurs, les drones ou même les smartphones. Ce qu'on gagne, c'est énorme : une latence réduite, une utilisation optimisée de la bande passante et une autonomie accrue, même dans des environnements isolés.

Mais évidemment, rien n'est parfait. Cette technologie, aussi prometteuse soit-elle, s'accompagne de défis. De défis techniques, oui, mais aussi éthiques et opérationnels. Ces défis ralentissent son adoption à grande échelle. Et comprendre ces limitations, c'est le premier pas pour trouver des solutions adaptées et exploiter tout le potentiel de l'Edge AI. Dans cette partie, nous allons explorer ces défis : qu'ils soient matériels, algorithmiques ou liés à des problématiques juridiques et éthiques.

1. Les défis matériels

a) Puissance de calcul réduite

Alors, parlons de la puissance de calcul, ou plutôt de son absence sur les appareils Edge. Ces appareils – qu'il s'agisse de capteurs IoT, de drones ou de petites caméras intelligentes – ne peuvent tout simplement pas rivaliser avec les centres de données. Les processeurs sont moins puissants, la mémoire est plus restreinte. Résultat ? Ces limitations brident leur capacité à exécuter des modèles d'IA complexes.

Pourquoi ? Plusieurs raisons. D'abord, pour réduire la taille. Les dispositifs Edge doivent être portables, compacts. On ne peut pas leur coller un énorme processeur ; ils doivent tenir dans un drone ou un capteur de la taille d'une boîte d'allumettes. Ensuite, il y a l'autonomie. Ces appareils fonctionnent souvent sur batterie, donc chaque calcul complexe grignote de l'énergie. Enfin, il y a le coût. Pour que l'Edge AI soit adoptée largement, les appareils doivent rester abordables. Et des composants très puissants coûteraient trop cher.

Quelles sont les conséquences ? Eh bien, tout d'abord, des réponses plus lentes. Si vous demandez à un assistant vocal sur un appareil Edge de vous donner la météo, vous pourriez attendre un peu plus longtemps qu'avec un modèle cloud. Ensuite, des résultats moins précis, car pour fonctionner sur des appareils restreints, les modèles d'IA doivent être simplifiés, parfois au détriment de leur exactitude. Enfin, certaines fonctionnalités sont carrément impossibles. Imaginez essayer de faire tourner un jeu vidéo ultraréaliste sur un smartphone : ce n'est pas faisable sans concessions majeures.

b) Contraintes énergétiques

Un autre problème critique : l'énergie. Beaucoup d'appareils Edge fonctionnent sur batterie, et ils doivent tenir le coup pendant de longues périodes. Pensez à un drone en mission de surveillance ou à un dispositif médical portable. Si la batterie se vide trop vite à cause d'algorithmes d'IA gourmands, le système devient inutile.

Ces contraintes énergétiques posent des défis importants, surtout pour des applications critiques où la fiabilité est essentielle. Les développeurs doivent donc constamment trouver des moyens d'optimiser l'efficacité énergétique des modèles qu'ils déploient.

c) Capacités de stockage limitées

Le stockage, lui aussi, est un casse-tête. Contrairement aux serveurs cloud, les appareils Edge n'ont que très peu d'espace mémoire. Cela signifie qu'il faut trouver un équilibre entre la taille des modèles, leur performance, et les données qu'ils doivent traiter. Ce défi oblige les développeurs à faire des choix difficiles pour que tout fonctionne correctement.

d) Résistance aux environnements hostiles

Enfin, n'oublions pas les environnements extrêmes. Les appareils Edge ne travaillent pas dans des bureaux climatisés. Ils se retrouvent souvent dans des usines poussiéreuses, des zones rurales, ou même accrochés à des drones en plein soleil. Ces conditions peuvent entraîner des pannes matérielles ou une baisse des performances. Pour survivre, les appareils doivent être robustes, conçus pour résister à la chaleur, au froid, ou aux vibrations.

2. Défis éthiques et juridiques

a) Confidentialité et sécurité des données

L'Edge AI traite souvent des données sensibles : des vidéos, des images, des informations personnelles. Et même si ces données sont analysées localement, cela ne signifie pas qu'elles sont totalement protégées. Un appareil Edge peut être piraté, et si cela arrive, les données collectées peuvent être volées ou mal utilisées.

Pour limiter ces risques, on utilise des technologies de chiffrement embarqué et des systèmes de détection d'intrusion. Mais même avec ces protections, le risque zéro n'existe pas.

b) Conformité réglementaire

Les lois sur la protection des données, comme le RGPD en Europe, imposent des règles strictes. Les entreprises qui utilisent l'Edge AI doivent garantir que leurs solutions respectent ces réglementations, ce qui peut être complexe, surtout si elles opèrent dans plusieurs régions du monde.

c) Biais et équité

Un autre problème majeur concerne les biais dans les modèles d'IA. Si un modèle est entraîné avec des données biaisées, il risque de reproduire ou d'amplifier ces biais. Cela peut avoir des conséquences graves, en particulier dans des domaines sensibles comme le recrutement ou la reconnaissance faciale. Pour éviter cela, les développeurs doivent mettre en place des mécanismes pour identifier et corriger ces biais.

d) Impact sociétal

Enfin, il y a l'impact sur la société. L'automatisation permise par l'Edge AI peut entraîner des pertes d'emploi dans certains secteurs. Et en cas d'erreur ou de dommage causé par un système Edge, qui est responsable ? Ces questions restent ouvertes et nécessitent une réflexion collective, mais aussi des réglementations adaptées.

VI. Solutions aux défis de l'Edge AI

1. Développement de processeurs spécialisés pour l'Edge AI

Les processeurs spécialisés, comme les TPU Edge ou les NPU, redéfinissent la manière dont les dispositifs Edge abordent l'intelligence artificielle. Leur conception unique maximise les performances tout en maîtrisant la consommation énergétique, un atout essentiel dans un monde où les dispositifs connectés se multiplient à vitesse grand V. Contrairement aux processeurs traditionnels, souvent mal adaptés aux exigences de l'IA moderne, ces unités spécialisées brillent par leur capacité à exécuter des calculs matriciels complexes et à traiter des tâches pointues, telles que la classification d'images ou la reconnaissance d'objets.

Prenons le Google Coral TPU. Véritable champion dans le domaine des applications embarquées, il exécute avec brio des modèles TensorFlow optimisés pour Edge, et ce, sans compromettre l'efficacité énergétique. De l'autre côté, le NVIDIA Jetson Nano s'impose comme un acteur incontournable pour des projets industriels sophistiqués. Que ce soit pour automatiser des processus ou détecter des objets en temps réel, il offre une puissance de calcul impressionnante et s'intègre parfaitement dans des environnements exigeants.

Ces technologies ne se contentent pas de répondre aux besoins actuels ; elles les devancent. Les TPU Edge s'illustrent par leur capacité à exécuter des modèles TensorFlow Lite de manière ultra-optimisée, tandis que les NPU s'appuient sur des accélérateurs matériels intégrés pour exceller dans les tâches de

deep learning. Grâce à eux, l'intelligence artificielle embarquée quitte le domaine de la science-fiction pour transformer notre quotidien.

2. Compression et optimisation des modèles IA

Les techniques d'optimisation et de compression des modèles IA jouent un rôle essentiel dans leur exécution sur des dispositifs Edge. Voici un aperçu des principales techniques utilisées :

a) Quantification

Cette technique réduit la précision numérique des poids et des activations d'un modèle, souvent de 32 bits (FP32) à 8 bits (INT8). Cela réduit considérablement la taille du modèle et sa consommation d'énergie sans perdre significativement en précision.




Figure : Illustration du processus de quantification binaire

Avantages : La quantification peut réduire la taille du modèle jusqu'à 4 fois et accélérer son exécution sur des dispositifs comme les TPU Edge.

b) Prunage (Pruning)

Le prunage consiste à supprimer les connexions ou les paramètres inutiles dans un réseau neuronal pour alléger le modèle sans affecter ses performances globales.




Figure : Illustration du Pruning dans un Réseau de Neurones

Avantages : Réduction de la taille du modèle sans perte significative de précision, surtout pour les couches où les poids sont proches de zéro.

c) Distillation de connaissances

Cette méthode entraîne un modèle léger (student model) à partir des prédictions d'un modèle plus complexe (teacher model). Le modèle léger hérite des caractéristiques du modèle complexe tout en étant beaucoup plus petit.




Figure : Illustration du processus de Knowledge Distillation.

3. Intégration de systèmes hybrides (Edge-Cloud)

Dans une architecture hybride Edge-Cloud, les dispositifs Edge et les infrastructures Cloud travaillent main dans la main pour offrir des performances optimales. Les dispositifs Edge, positionnés au plus près des utilisateurs ou des objets, exécutent des tâches critiques en temps réel, comme la reconnaissance d'objets ou la détection d'anomalies. Pendant ce temps, le Cloud se concentre sur des calculs plus complexes, tels que l'entraînement de modèles d'intelligence artificielle ou l'analyse approfondie des données. Ce partenariat stratégique permet une répartition intelligente des charges de travail : les caméras Edge, par exemple, peuvent détecter des anomalies et transmettre uniquement les séquences pertinentes au Cloud pour une analyse détaillée. De même, dans le domaine de la santé connectée, les dispositifs Edge surveillent les patients en temps réel, tandis que les données historiques sont centralisées dans le Cloud pour détecter des tendances médicales ou émettre des prédictions.

Une architecture Edge-Cloud typique pourrait inclure un dispositif Edge qui capture et analyse les données localement, tout en restant connecté à un serveur Cloud pour des traitements approfondis et une gestion centralisée des informations. Ce schéma est essentiel pour combiner rapidité d'exécution et puissance d'analyse, répondant ainsi aux besoins croissants d'applications intelligentes et réactives.




Figure : Illustration d'un système hybride Edge-cloud

Conception de dispositifs résistants et économes en énergie

Pour que ces dispositifs Edge soient véritablement performants, ils doivent être conçus pour résister à des environnements difficiles tout en étant économes en énergie. Dans l'agriculture, par exemple, les capteurs IoT doivent supporter des conditions extrêmes, comme la pluie, la poussière ou des températures élevées, tout en fonctionnant de manière autonome grâce à l'énergie solaire. Cela nécessite des boîtiers étanches pour protéger les composants électroniques, des batteries optimisées pour maximiser l'autonomie, et l'utilisation de composants à faible consommation, comme les microcontrôleurs ARM Cortex. Ces choix technologiques permettent non seulement d'assurer la robustesse des dispositifs, mais aussi de répondre aux contraintes énergétiques des applications Edge, souvent déployées dans des lieux isolés ou sans accès constant à une alimentation électrique.

4. Mise en place de normes et protocoles de sécurité avancés

On ne peut pas parler de l'IA en périphérie sans parler de la protection des données sensibles qui sont collectées sur ces appareils Edge. Assurer la protection des données sensibles est aujourd'hui une priorité absolue dans le développement des dispositifs Edge. Pour y parvenir, on doit mettre en place des protocoles de sécurité avancés, comme le chiffrement de bout en bout. Par exemple, un dispositif Edge intégré à un système de vidéosurveillance peut chiffrer localement les séquences vidéo dès leur capture. Cette mesure garantit que les données restent illisibles pour d'éventuels tiers malveillants, même en cas d'interception.

On observe également que des systèmes de détection d'intrusion jouent un rôle crucial dans ce contexte. Avec ces systèmes, on est capable d'alerter les utilisateurs dès qu'un accès non autorisé est détecté, renforçant ainsi la vigilance face aux menaces potentielles. Grâce à ces dispositifs, non seulement les données personnelles des utilisateurs sont mieux protégées, mais la confiance envers les solutions Edge s'en trouve grandement renforcée. Ces efforts démontrent clairement que la sécurité des données n'est pas qu'un enjeu technique : elle est au cœur de la relation entre les utilisateurs et les technologies connectées.

5. Conformité proactive avec les réglementations

Les entreprises n'ont plus d'autre choix que de se conformer à des lois strictes, comme le RGPD, pour protéger efficacement les données personnelles des utilisateurs. Cela implique des pratiques concrètes, telles que l'anonymisation des données ou le traitement local des informations sensibles. Par exemple, un dispositif Edge utilisé dans une application de santé peut traiter les données biométriques directement sur place, éliminant ainsi les risques liés à des transferts non autorisés vers des serveurs distants.

Ces pratiques ne se contentent pas de réduire les risques de sanctions légales. Elles incarnent également un engagement fort envers la protection de la vie privée des utilisateurs. En adoptant ces mesures, les entreprises ne protègent pas seulement leurs intérêts, elles montrent qu'elles prennent réellement au sérieux la sécurité des données. Cette démarche contribue à renforcer la confiance des utilisateurs dans les technologies qu'ils utilisent au quotidien.



Figure : Voici une carte montrant les lois mondiales sur la confidentialité des données

6. Développement d'algorithmes anti-biais

Les biais dans les modèles d'intelligence artificielle peuvent entraîner des décisions injustes ou discriminatoires. Pour éviter cela, des algorithmes capables de détecter et de corriger ces biais doivent être développés. Par exemple, dans un système de reconnaissance faciale embarqué, des outils comme

“Fairness Indicators” peuvent analyser si le modèle fonctionne équitablement pour différents groupes démographiques. Cela garantit que les décisions prises par les dispositifs Edge sont justes et inclusives.

7. Sensibilisation et éducation des développeurs

Les développeurs jouent un rôle crucial dans la création de systèmes Edge respectueux des normes éthiques. Les former sur des sujets comme la gestion des biais ou la sécurité des données est essentiel. Par exemple, des ateliers ou des cours universitaires sur les impacts sociaux de l’IA peuvent aider les équipes à mieux comprendre les implications de leurs travaux. Cette sensibilisation réduit les erreurs et garantit que les technologies sont conçues avec un sens de la responsabilité.

VII. Perspectives et opportunités d’avenir

1. Améliorations attendues dans les puces et algorithmes

L’avenir de l’Edge AI repose largement sur les avancées technologiques dans le matériel et les algorithmes. Les fabricants de semi-conducteurs se concentrent sur le développement de processeurs plus puissants, écoénergétiques et spécialisés. Par exemple, des entreprises comme NVIDIA, ARM et Qualcomm investissent dans des architectures dédiées au traitement de l’IA sur les appareils.

Les modèles d’IA plus légers deviendront la norme grâce à des approches comme le "Sparse Training", qui réduit la densité des paramètres sans affecter significativement les performances. En outre, l’évolution de la "Quantification Post-training" permettra une meilleure prise en charge des appareils à faible capacité.

2. Nouvelles applications potentielles

L’Edge AI est en train de transformer plusieurs domaines encore largement inexplorés, en apportant des solutions concrètes et adaptées à des besoins spécifiques.

Dans l’éducation, elle ne se contente pas seulement d’adapter les contenus en temps réel. Grâce à des appareils portables et à la réalité augmentée, elle crée des expériences d’apprentissage interactives, rendant les cours plus engageants et accessibles à tous, que ce soit en classe ou à distance.

En agriculture, les capteurs intelligents ne se limitent pas à analyser le sol et la météo. Ils permettent aussi d’anticiper les besoins en irrigation ou en fertilisation, tout en identifiant les menaces comme les parasites, ce qui aide à réduire les pertes et à maximiser les récoltes. Dans le commerce, l’Edge AI va au-delà de simples écrans connectés et chatbots. Elle permet de personnaliser en profondeur parcours

d'achat, avec des suggestions en temps réel et une meilleure gestion des stocks, offrant ainsi une expérience client plus fluide et adaptée.

En combinant innovation et efficacité, cette technologie ouvre des perspectives infinies, en changeant la manière dont nous interagissons avec le monde qui nous entoure.

3. Effets de la réglementation sur le développement de l'Edge AI

Les règles sur la confidentialité des données, comme le RGPD, ont un gros impact sur le développement de l'Edge AI. En traitant les données directement sur place, cette tech respecte les exigences de sécurité et de protection de la vie privée, tout en évitant les risques liés au partage de données sensibles.

Mais pour que l'Edge AI puisse vraiment se développer partout dans le monde, il faudra aligner les standards entre les différents pays. Sinon, ça restera compliqué pour les entreprises d'adopter cette technologie tout en respectant toutes les lois locales.

L'Edge AI a donc un énorme potentiel : elle répond aux attentes actuelles sur la confidentialité des données tout en ouvrant la porte à un futur plus connecté, mais il faudra un vrai travail d'équipe à l'échelle mondiale pour y arriver.

4. Collaboration entre le cloud et l'Edge AI

L'interconnexion entre le cloud et l'Edge AI devient de plus en plus essentielle, car elle permet de combiner leurs forces pour offrir des solutions ultra performantes et adaptées aux besoins actuels.

Avec l'Edge AI, on peut gérer des tâches critiques qui exigent une réactivité quasi instantanée, comme dans les voitures autonomes ou les systèmes médicaux d'urgence, où chaque milliseconde peut faire la différence. En parallèle, le cloud joue un rôle complémentaire en centralisant les données collectées et en utilisant sa puissance de calcul pour entraîner des modèles d'intelligence artificielle plus avancés et complexes.

Cette synergie ne se contente pas de répartir les tâches, elle optimise vraiment la manière dont l'intelligence artificielle est utilisée au quotidien. C'est un duo gagnant : la rapidité de l'Edge AI et la puissance du cloud s'associent pour créer des solutions efficaces, que ce soit pour répondre aux besoins d'une seule personne ou pour gérer des systèmes à grande échelle.

VIII. Études de cas

1. Exemple de mise en œuvre réussie dans l'industrie automobile

▪ Les voitures autonomes : Tesla et Nvidia

Tesla a su se démarquer dans le domaine des voitures autonomes en intégrant des puces spécialement conçues pour l'Edge AI dans ses véhicules. Ces technologies permettent aux voitures de traiter un volume énorme de données directement à bord, sans dépendre constamment d'une connexion réseau. Cette capacité à analyser l'environnement en temps réel est essentielle pour offrir une conduite assistée fluide et sécurisée. De son côté, Nvidia joue également un rôle clé en proposant des solutions de calcul ultra-performantes avec ses processeurs Jetson. Ces puces garantissent une faible latence, un élément crucial pour des décisions rapides et précises dans des situations critiques, comme un freinage d'urgence ou l'évitement d'obstacles. Ensemble, ces innovations montrent à quel point l'alliance entre puissance de calcul et intelligence artificielle est au cœur des progrès dans les véhicules autonomes. Elles préfigurent un avenir où les voitures seront capables d'apprendre et de s'adapter en temps réel pour garantir la sécurité et l'efficacité des trajets.

2. Cas d'une ville intelligente utilisant l'Edge AI

▪ Singapour : Un modèle de gestion urbaine intelligente

Singapour est souvent citée comme un exemple à suivre en matière de gestion urbaine intelligente, et ce n'est pas sans raison. Grâce à l'utilisation de l'Edge AI, la ville peut analyser les flux de trafic en temps réel. Cette technologie permet d'ajuster automatiquement les feux de signalisation pour fluidifier la circulation et réduire considérablement les embouteillages. Mais cela ne s'arrête pas là. Singapour a également équipé ses bâtiments de capteurs intelligents capables de surveiller en permanence la consommation énergétique. Ces systèmes adaptent automatiquement les équipements, comme la climatisation, pour atteindre une efficacité énergétique optimale tout en maintenant le confort des occupants. En combinant ces innovations, Singapour montre qu'il est possible d'améliorer la qualité de vie tout en réduisant l'impact environnemental. Ce modèle démontre la puissance de l'intelligence artificielle lorsqu'elle est intégrée dans des systèmes urbains pour anticiper les besoins et agir de manière proactive.

3. Utilisation de l'Edge AI dans le secteur de la santé

▪ Dispositifs médicaux : Les wearables intelligents

Les wearables intelligents révolutionnent le domaine médical, et les montres connectées en sont un parfait exemple. Parmi les avancées marquantes, on trouve leur capacité à détecter des anomalies cardiaques en temps réel, ce qui a un impact significatif sur la prévention et la gestion des maladies cardiovasculaires. En 2022, Apple a franchi une étape importante en introduisant une fonctionnalité basée sur l'Edge AI dans ses Apple Watches. Cette technologie permet aux montres de détecter des cas de fibrillation auriculaire directement sur l'appareil, sans dépendre d'une connexion constante au cloud. Cela offre une rapidité et une autonomie cruciales, notamment pour les utilisateurs vivant dans des zones où l'accès à internet est limité. Ces dispositifs ne se contentent plus de collecter des données : ils deviennent des outils de diagnostic précoce, rapprochant les soins médicaux des individus et rendant la santé plus proactive et accessible. Avec de telles innovations, les wearables intelligents ouvrent la voie à un suivi de santé personnalisé et efficace.

IX. Cas pratique

Afin de montrer l'utilisation de l'Edge IA en temps réel et mieux comprendre le mécanisme, on a opté à développer une application mobile qui va détecter six catégories de déchets à l'aide de Tensorflow Lite et Flutter l'environnement de développement pour garantir la fluidité, l'efficacité et une interface intuitive.

1. Base de données

Comme première étape cruciale du projet, on a commencé par collecter un ensemble varié et représentatif d'images de déchets. Des images d'aluminium, de carton, de verre, de plastique, de déchets organiques et de déchets électroniques a été enregistré de différentes sources. Ensuite, on a prétraité et annoté les images afin de créer un ensemble de données prêt à être utilisé pour l'apprentissage supervisé.

Nous avons créé six dossiers, chaque dossier est nommé par une catégorie, afin d'avoir une base de données structuré, simple et facile à comprendre.




Figure 7 : Vue de l'arborescence des dossiers du dataset classés par catégorie

2. Technologies adaptées

Pour le développement nous avons utilisé diverses technologies. Voici un aperçu des technologies principales utilisées :



Python un langage de programmation orienté objet facile à interpréter et de haut niveau avec une syntaxe facile à lire, en utilisant différentes bibliothèques telles que TensorFlow et Keras pour la création et l'optimisation du modèle, NumPy et Pandas pour manipuler et analyser les données, ainsi qu'OpenCV pour le traitement des images et la préparation des données d'entraînement.



Un Framework open source développé par google pour créer des applications Android, IOS, web à partir d'un seul codebase.

Son langage de programmation c'est Dart, qui est un langage optimisé pour les applications modernes. Dans un projet flutter le dossier principal contient plusieurs sous-dossiers qui correspondent aux différentes plateformes sur lesquelles l'app peut être déployée.

Dossier_projet/

| -- android/ # Code spécifique pour Android (Java/Kotlin)

| -- ios/ # Code spécifique pour iOS (Swift/Objective-C)

| -- linux/ # Code spécifique pour Linux (C++)

| -- macos/ # Code spécifique pour macOS (Swift/Objective-C)

| -- windows/ # Code spécifique pour Windows (C++)

| -- web/ # Code spécifique pour les applications web (HTML, JS)

```
|-- lib/ # Code principal en Dart (UI et logique métier)

|-- assets/ # Images, polices, fichiers statiques

|-- pubspec.yaml # Configuration du projet librairies et dépendances

|-- test/ # Tests unitaires et d'intégration
```

3. Modèles et évaluation

Afin d'atteindre notre but de classer les déchets domestiques, nous avons examiné différentes structures de modèles de réseaux de neurones convolutifs (CNN). Nous avons analysé les résultats de ces modèles afin de choisir celui qui présente la précision la plus élevée.

Le Modèle d'Intelligence Artificielle opté pour notre application c'est le modèle « MobileNetV2 » qui est un réseau pré-entraîné de neurones convolutifs qui propose un excellent équilibre entre précision et rapidité, ce qui le rend parfait pour une utilisation sur mobile.

```
# Charger le modèle MobileNetV2 pré-entraîné sans les couches de classification
base_model = MobileNetV2(weights='imagenet', include_top=False, input_shape=(128, 128, 3))

# Geler les couches de MobileNetV2
for layer in base_model.layers:
    layer.trainable = False

# Ajouter les couches de classification personnalisées
model = Sequential([
    base_model,
    Flatten(),
    Dense(512, activation='relu'),
    Dropout(0.5),
    Dense(6, activation='softmax')
])

# Compiler le modèle
model.compile(optimizer=Adam(learning_rate=0.001), loss='categorical_crossentropy', metrics=['accuracy'])

# Entraîner le modèle
history = model.fit(datagen.flow(train_data, train_labels, batch_size=32),
                    epochs=20,
                    validation_data=(test_data, test_labels))
```

Figure 8 : Capture d'écran du code d'apprentissage du modèle MobileNetV2

Un modèle d'intelligence artificielle optimisé pour les appareils mobiles pour une détection de déchets en temps réel directement sur le smartphone sans avoir besoin du cloud ou d'une connexion internet.

La technologie utilisée pour ce modèle c'est le tensorflow lite (.tflite) c'est une version allégée de tensorflow pour les smartphones. Cela permet d'avoir des performances rapides, une faible consommation d'énergie et assurer une plus grande autonomie puisqu'elle fonctionne hors connexion.

4. Environnement de développement

Comme IDE on a utilisé Android studio et Visual Studio Code pour le développement et le débogage.




Figure 9 : Logo de Visual Studio Code



Figure 10 : Logo d'Android Studio

Ces technologies nous ont permis de concevoir une application mobile facile à utiliser et capable de détecter efficacement et de manière autonome les déchets.

5. Interface utilisateur

L'interface utilisateur de notre application est très simple et facile à manipuler. Il suffit de cliquer sur le bouton « Take Picture » pour accéder à la caméra du smartphone, prendre une photo du déchet, cette photo va être envoyée et traitée à l'aide de notre modèle pour la prédiction et finalement l'affichage du résultat.




Figure 11 : Aperçu de l'interface utilisateur de l'application mobile

X. Recommandations pour l'implémentation de l'Edge AI

1. Stratégies pour intégrer l'Edge AI dans les entreprises

Intégrer de l'Edge AI dans le cadre de l'entreprise est un enjeu stratégique important. La première étape pour son adoption est d'analyser l'entreprise et ses différents services pour savoir quels services peuvent bénéficier d'une analyse locale et rapide des données. Il est aussi très important dans le cadre de l'entreprise de regarder le budget disponible pour ce "projet" et de comparer les coûts et de spéculer sur les retours sur investissement.

Tout le système déjà existant doit-être re adapter pour supporter l'Edge ai. Faire monter en compétences les équipes internes est aussi une étape importante pour gérer de manière autonome ces intégrations Edge. Pour limiter un maximum les risques il faut commencer par implémenter des petits projets assez basiques et surtout bien sûr de lancer tous les tests dans un environnements bac à sable avant de finalement déployer sur l'environnement PROD de l'entreprise.

Travailler avec des experts dans la technologie Edge est une bonne idée pour accélérer l'intégration de cette dernière mais il ne faut pas oublier que l'objectif principal dans cette transition est la sécurité des données.

Enfin pour terminer il faut analyser les résultats et mesurer les performances de l'Edge AI pour être certain que les résultats obtenus sont ceux attendu.

2. Pratiques exemplaires pour la sécurité et la maintenance

La sécurité des appareils Edge et leur maintenance sont importantes pour réussir l'utilisation de l'Edge AI. Voici quelques conseils clés :

- Les appareils Edge doivent utiliser des systèmes de cryptage pour les données envoyées ou stockées. Il est aussi important d'installer une authentification à plusieurs facteurs pour éviter tout risque qu'un appareil non autorisé parviennent à accéder à ces données.
- Il faut aussi appliquer régulièrement les correctifs de sécurité. On peut aussi automatiser certains processus tant qu'il est contrôlé par un humain.
- Dans le cadre de la sécurité il est important de faire du "monitoring" ou d'utiliser des outils pour faire du "monitoring" qui signifie surveillance. Ces outils auront pour but de détecter des anomalies. De plus les journaux d'activité doivent être vérifiés quotidiennement.
- Enfin, il est du même ordre d'importance de former les équipes sur les technologies Edge que sur la sécurité. Une fois que les équipes sont montées en compétences sur ce sujet, il est bien de leur faire des piques de rappel par des mini-exercices pour éviter l'erreur humaine qui sont souvent à l'origine des problèmes de sécurité.

En suivant ces conseils, les entreprises peuvent s'assurer que leurs dispositifs Edge sont sécurisés et sont fonctionnelles sur le long terme.

3. Approches pour réduire la consommation d'énergie

Les appareils Edge utilisent des matériaux qui sont peu coûteux en énergie. Le développement du code et les algorithmes utilisés doivent aussi être révisés pour utiliser le moins de ressources.

Un bon moyen pour réduire la consommation d'énergie et de mettre ces appareils sur le mode veille quand ils ne sont pas utilisés. On peut aussi imaginer mettre en place des modes basses consommation pour réduire la consommation sans perdre en efficacité.

Une autre façon de réduire la consommation d'énergie est de réduire l'envoi de données inutiles ou bien de compresser les données avant l'envoi.

La meilleure façon de trouver d'autres solutions sur la question de la consommation d'énergie est de surveiller ce qui consomme le plus afin d'adopter une bonne stratégie.

Enfin la meilleure option serait d'utiliser des énergies renouvelables pour alimenter les appareils Edge ai. Cela réduit les coûts sur le long terme et aide à protéger la planète.

4. Collaboration avec les fournisseurs de technologies

Les fabricants de puces et les développeurs de logiciels jouent un rôle important dans la mise en place des solutions Edge ai. Les fabricants conçoivent des puces qui sont spécialisées tout en restant adaptées aux besoins des entreprises. Cela permet de s'assurer que le matériel correspond exactement aux attentes.

Les développeurs, de leur côté, créent des outils qui permettent d'exploiter pleinement les capacités de ces appareils. Cela aide aussi à suivre les dernières avancées et à être toujours à la pointe de la technologie.

En travaillant ensemble, les entreprises peuvent accélérer leurs projets, résoudre les problèmes techniques plus rapidement, et adopter des solutions qui fonctionnent bien dès le départ. Cette collaboration aide aussi à rester à jour avec les nouvelles technologies, ce qui est crucial dans un domaine aussi rapide que l'Edge AI.

En fin de compte, cette collaboration garantit que les solutions Edge AI soient non seulement efficaces, mais aussi parfaitement adaptées aux attentes des entreprises, tout en étant préparées pour l'avenir.

XI. Conclusion

Edge IA a connu une forte croissance ces dernières années en raison de sa capacité à traiter des données plus près de la source, réduisant ainsi le temps de réponse et améliorant l'efficacité. Les techniques de cette technologie jouent un rôle essentiel dans la possibilité d'une prise de décision intelligente sur les dispositifs à l'écran. Le concepts "Edge" et "Intelligence" sont simplement des éléments d'une solution globale qui comprend une meilleure manipulation des données, une plus grande autonomie et transparence dans les opérations, ainsi qu'une entreprise plus agile et adaptable. Edge AI et Industry 4.0 sont étroitement liés, avec Edge AI jouant le rôle de catalyseur pour des systèmes intelligents, décentralisés et autonomes dans le domaine de la fabrication. Cette intégration offre des analyses en temps réel, un traitement local, une sécurité améliorée et une connexion Edge-to-cloud, permettant ainsi des usines intelligentes, une maintenance prédictive et des opérations

industrielles optimisées. En exploitant le potentiel de Edge AI au sein de l'industrie 4.0, les entreprises peuvent découvrir de nouvelles dimensions d'efficacité, de productivité et d'innovation dans le domaine de la fabrication.

On prévoit que l'avenir d'Edge AI sera dynamique et transformateur, car elle continue de se développer et de répondre à divers défis. Comme l'Edge Computing devient de plus en plus répandu, il y aura toujours des améliorations continues des capacités informatiques des Edge devices. Cela entraînera l'apparition de processeurs plus puissants et économes en énergie ainsi que de puissants accélérateurs spécialement conçus pour les tâches d'IA. Le marché des chips d'intelligence artificielle à bord a connu une forte croissance (AI chips - rendre le traitement de l'IA possible sur pratiquement tous les appareils intelligents (montres, appareils photo, appareils de cuisine) dans le cadre d'un processus connu sous le nom d'IA de pointe.), et il est prévu que le secteur connaîtra une expansion significative dans les prochaines années. Edge AI et cloud Computing vont s'associer de manière plus fluide, créant ainsi un écosystème hybride où les données et la manipulation sont dynamiquement réparties entre les dispositifs à proximité et les serveurs cloud centralisés. Grâce à cette synergie, des applications AI seront plus performantes et évolutives.

XII. Bibliographie et Annexes

- [1] *Edge Computing – Rechenleistung, wo sie gebraucht wird* | Codeatelier. (s. d.). <https://codeatelier.com/blog/edge-computing-rechenleistung-wo-sie-gebraucht-wird>

- [10] Xu, Y., Cao, J., & Jiang, X. (2020). Edge AI in Smart Video Surveillance: Challenges, Advances, and Opportunities. *IEEE Network*, 34(5), 216-222.doi:10.1109/MNET.011.2000334

- [11] Glover, E. (2024, 3 décembre). *AI chips : What are they ?* Built In. <https://builtin.com/articles/ai-chip#:~:text=AI%20chips%20make%20AI%20processing,improving%20security%20and%20energy%20efficiency>

- [12] Yassin Kortli, SouhirGabsi, Lew F.C. Lew Yan Voon, Maher Jridi, MehrezMerzougui, Mohamed Atri,Deep embedded hybrid CNN–LSTM network for lane detection on NVIDIA Jetson Xavier NX,Knowledge-Based Systems,Volume 240,2022,107941,ISSN 0950-7051, <https://doi.org/10.1016/j.knosys.2021.107941> .

- [13] *Intelligence accrue à l'Edge grâce à l'IA* | NVIDIA. (s. d.). <https://www.nvidia.com/fr-fr/edge-computing/edge-ai/idc-whitepaper-thank-you.html?form-submit->

[token=eyJ0eXAiOiJKV1QiLCJhbGciOiJIUzI1NiJ9.eyJ1c2VyLVVtYWlsIjoieXRyaWtpMUBteWdlcy5mcil-slmZvcM0tcGF0aCI6Ij9jb250ZW50L2ZvcM1zL2FmL252aWRpYS1mb3Jtcy9IZGdlLWNvbXB1dGluZyIsIn-ZvbHRyb24tc3VibWlzc2lubi1jb2RlIjoieTVRjeU9EUTNPRGt5T1RjNE53PT0iLCJpc3MiOiJudmlkaWEtYXV0aCIsInN1Ym1pc3Npb24tdGltZSI6IldlZCBPY3QgMDkgMDk6MDI6MDkgRURUIdlWmJjQjIleHAiOiE3MigOODAxMjksImtleSI6Ikt1uZEVxTXBLeM4QXhrR2dmdnFwVWRHaUFGQ2dOZSIsImZvcM0tbmFtZSI6ImluY3JlYXNpbmctaW50ZWxsaWdlbmNILWF0LXRoZS1IZGdlLXdpdGgtYWktZm9ybSIsInNlc3Npb24taWQiOiIzbnEQwY1pHNXk0SWZZU201bkhzaTVBVDVvdUM2YkQifQ.nMZLehBQRtRaj7cmrgDditTA0bjBCG45TFVBT-WXwxo](https://www.hpe.com/fr/fr/what-is/edge-ai.html)

[14] Johannes Betz, Hongrui Zheng, Alexander Liniger, Ugo Rosolia, Phillip Karle, Madhur Behl, Venkat Krovi, Rahul Mangharam: Autonomous Vehicles on the Edge: A Survey on Autonomous Vehicle Racing, IEEE Open Journal of Intelligent Transportation Systems, 2022.

[15] <https://www.hpe.com/fr/fr/what-is/edge-ai.html>

[16] StartUs Insights. (2023, 19 juillet). *Explore the Top 10 Edge Computing Trends in 2024*. <https://www.startus-insights.com/innovators-guide/edge-computing-trends/>

[17] Udemy. (s. d.). <https://www.udemy.com/course/edge-ai-and-edge-computer-vision/?couponCode=ST13MT100824>

[18] Udemy. (s. d.). <https://www.udemy.com/course/edge-ai-and-edge-computer-vision/?couponCode=ST13MT100824>

[19] Staff, W. (2024, 8 avril). *Introduction | 2024 State of Edge AI Report*. Wevolver. <https://www.wevolver.com/article/2024-state-of-edge-ai-report/introduction>

[20] Nachez, S. (s. d.). *L'Edge AI : la technologie en plein essor qui mêle intelligence artificielle et edge computing*. ActuaIA. <https://www.actuia.com/actualite/ledge-ai-la-technologie-en-plein-essor-qui-mele-intelligence-artificielle-et-edge-computing/>

